

Estandarización: separar el nivel de la estructura

Universidad Michoacana de San Nicolás de Hidalgo · Facultad de Ciencias Físico Matemáticas

Una hora de teoría · una hora de laboratorio

La deuda que traemos 6 min

Esta sesión paga una deuda que el curso lleva arrastrando desde la segunda clase. La pregunta se planteó dos veces:

LA PREGUNTA ABIERTA

En la **sesión 2** se dijo que **no se pueden comparar entre poblaciones con estructuras por edades distintas**, y se dejó para después el por qué y el qué hacer en su lugar.

En la **sesión 4** apareció otra vez, por el otro lado: resultó que la **sí** se puede comparar, y la razón era que se construye aplicando las tasas por edad a una cohorte hipotética *siempre igual*. Se dijo ahí que eso era «una estandarización sin nombre».

Hoy le ponemos el nombre, la fórmula y el procedimiento — y se verá que sirve para cualquier indicador, no solo para la mortalidad. En la unidad 2 se usará con fecundidad y en la 3 con migración.

POR QUÉ ESTO IMPORTA MÁS DE LO QUE PARECE

El criterio de labo2 que pedía usar la tasa bruta para *matizar* una conclusión salió al 81%, y el que pedía calcularla con los datos propios al 62%. O sea: el grupo sabe que la tasa bruta no basta, pero todavía no tiene con qué reemplazarla. Eso es lo que falta, y es lo que hoy se cierra.

Y no es un tecnicismo. La estandarización es **la herramienta más usada de toda la demografía aplicada** y la que separa un informe defendible de uno que dice lo

contrario de la verdad. El bloque 2 es un caso donde la conclusión se invierte por completo.

Para arrancar. Dos municipios tienen la misma mortalidad a cada edad, pero el primero es un municipio universitario lleno de jóvenes y el segundo es un pueblo de donde emigraron los jóvenes. ¿Qué tasa bruta de mortalidad tendrá cada uno?

- ☐ a) La misma, porque la mortalidad por edad es la misma.
- ☐ b) Mayor la del municipio universitario, porque tiene más gente.
- ☐ c) Mayor la del pueblo, porque tiene más gente en las edades donde se muere.
- ☐ d) No se puede saber sin conocer las tasas.

1. La tasa bruta es un promedio ponderado

11 min

La clave de toda la sesión es una identidad de dos líneas. Una vez escrita, todo lo demás es consecuencia.

NOTACIÓN

- ${}_nN_x$ — población del grupo de edad x ; $N = \sum_x {}_nN_x$ la población total.
- ${}_nD_x$ — defunciones de ese grupo; $D = \sum_x {}_nD_x$ el total.
- ${}_nM_x = {}_nD_x / {}_nN_x$ — la del grupo.
- $c_x = {}_nN_x / N$ — la **proporción** de la población que está en ese grupo. El vector (c_x) es la , y cumple $\sum_x c_x = 1$.

PROPOSICIÓN (LA DESCOMPOSICIÓN DE LA TASA BRUTA)

$$\text{TBM} = \frac{D}{N} = \sum_x c_x \cdot {}_nM_x.$$

La tasa bruta es el **promedio de las tasas específicas, ponderado por la estructura por edades**.

► Ver la deducción (tres pasos, ninguna hipótesis)

LO QUE LA IDENTIDAD REVELA, Y ES TODO

La tasa bruta depende de **dos cosas distintas**, y las mezcla sin dejar ver cuál es cuál:

EL NIVEL

Las tasas ${}_nM_x$: qué tan mortal es cada edad. Es lo que **queremos** comparar — es la salud de la población.

LA ESTRUCTURA

Los pesos c_x : cuánta gente hay en cada edad. Es lo que **contamina** la comparación — describe la historia demográfica, no la salud.

Y de ahí sale la idea de la solución, que es casi obvia una vez que la identidad está escrita: **si el problema son los pesos, hay que usar los mismos pesos para todos**. Poner la misma estructura en las dos poblaciones deja el nivel como lo único que puede variar.

Es exactamente lo que e_0 hacía sin decirlo: aplicar las tasas de cada entidad a una cohorte de 100 000 *siempre igual*.

EJEMPLO 1 · LA DESCOMPOSICIÓN, CON NÚMEROS

Trabajaremos toda la sesión con tres grupos de edad, para que las cuentas se puedan seguir a mano, y con tasas por mil. Dos entidades:

	estructura c_x	tasas ${}_nM_x$ (‰)
A — entidad joven	(0.35, 0.60, 0.05)	(1.5, 3.0, 55.0)
B — entidad envejecida	(0.20, 0.62, 0.18)	(1.0, 2.5, 50.0)

Los grupos son 0-14, 15-64 y 65+, y las dos estructuras suman 1. Descomponiendo la tasa bruta de cada una, término por término:

$$TBM_A = (0.35)(1.5) + (0.60)(3.0) + (0.05)(55.0) = 0.525 + 1.800 + 2.750$$

$$TBM_B = (0.20)(1.0) + (0.62)(2.5) + (0.18)(50.0) = 0.200 + 1.550 + 9.000$$

Vale la pena mirar de dónde sale cada tasa bruta. En A, el grupo de 65 y más aporta 2.750 de los 5.075 —**54%** de las muertes con solo el 5% de la población—. En B ese mismo grupo aporta 9.000 de 10.750, o **84%**. La tasa bruta de B está casi enteramente decidida por su proporción de adultos mayores.

2. El caso que invierte la conclusión

12 min

Con los mismos números del ejemplo 1, ahora la pregunta de fondo: **¿en cuál de las dos entidades se muere más?**

EJEMPLO 2 · LO QUE DICEN LAS TASAS BRUTAS

$$TBM_A = 5.075 \text{ ‰} \quad TBM_B = 10.750 \text{ ‰} \quad \frac{TBM_B}{TBM_A} = 2.12$$

Leído sin más: **en B se muere el doble que en A**. Con esa cifra se escriben notas de prensa, se reparten presupuestos de salud y se decide dónde poner una clínica.

EJEMPLO 3 · LO QUE DICEN LAS TASAS POR EDAD

Ahora comparemos edad por edad, que es lo que de verdad describe la mortalidad:

grupo	${}_nM_x$ en A	${}_nM_x$ en B	razón A / B
0-14	1.5 ‰	1.0 ‰	1.50
15-64	3.0 ‰	2.5 ‰	1.20
65+	55.0 ‰	50.0 ‰	1.10

La entidad A tiene mortalidad MÁS ALTA que B en los tres grupos de edad, sin excepción. A cada edad concreta, una persona tiene más riesgo de morir en A que en B.

Y sin embargo su tasa bruta es la mitad. La conclusión que se saca de la tasa bruta no es imprecisa: es **exactamente la contraria** de la verdad.

CÓMO ES POSIBLE, CON LA IDENTIDAD EN LA MANO

Ya tenemos la respuesta del bloque 1: $TBM = \sum_x c_x {}_nM_x$. La tasa bruta de A es baja no porque sus tasas sean bajas —no lo son— sino porque su **peso** en el grupo de alta mortalidad es de solo 0.05 contra 0.18 de B. La estructura pesa más que el nivel:

grupo 65+	A	B
tasa ${}_nM_x$	55.0 ‰ (mayor)	50.0 ‰
peso c_x	0.05	0.18 (3.6 veces)
aportación	2.750	9.000

La tasa de A es 1.1 veces la de B, pero el peso de B es 3.6 veces el de A. Gana el peso, y por mucho.

Este fenómeno —que el agregado ordene al contrario que todos sus componentes— tiene nombre en estadística: se le llama la **paradoja de Simpson**. No es una paradoja lógica: es lo que pasa cuando se promedia con pesos distintos y se compara el promedio como si los pesos fueran iguales.

Compruébalo. ¿Qué habría que cambiar en el cálculo para que la comparación entre A y B sí midiera la mortalidad y no la estructura?

- ☐ a) Usar los MISMOS pesos c_x para las dos, dejando que cada una conserve sus propias tasas.
- ☐ b) Usar las mismas tasas para las dos, dejando que cada una conserve su estructura.
- ☐ c) Dividir la tasa bruta de cada una entre su proporción de adultos mayores.

- ☐ d) Comparar solo el grupo de 65 y más, que es donde ocurre casi todo.

3. Estandarización directa

10 min

DEFINICIÓN (TASA ESTANDARIZADA POR EL MÉTODO DIRECTO)

Se elige una **población estándar** con estructura c_x^s , y para cada población de estudio se calcula

$$\text{TME} = \sum_x c_x^s \cdot {}_nM_x^{\text{estudio}}.$$

En palabras: **las tasas de la población que se estudia, pesadas con la estructura del estándar**. Es la tasa bruta que esa población *tendría* si su estructura por edades fuera la del estándar.

Siegel & Swanson (2004), *The Methods and Materials of Demography*, pp. 306-310 del PDF, donde se comparan los cuatro métodos de ajuste por edad · Preston, Heuveline & Guillot (2001), cap. 1 y cierre del cap. 3.

EJEMPLO 4 · A Y B CON LA MISMA ESTRUCTURA

Tomamos como estándar la estructura nacional, $c^s = (0.27, 0.61, 0.12)$, que suma 1. Y aplicamos **a cada entidad sus propias tasas**, con esos pesos comunes:

$$\text{TME}_A = (0.27)(1.5) + (0.61)(3.0) + (0.12)(55.0) = 0.405 + 1.830 + 6$$

$$\text{TME}_B = (0.27)(1.0) + (0.61)(2.5) + (0.12)(50.0) = 0.270 + 1.525 + 6$$

Y aquí está el resultado de la sesión:

	A	B	conclusión
tasa bruta	5.075 ‰	10.750 ‰	«en B se muere 2.1 veces más»
tasa estandarizada	8.835 ‰	7.795 ‰	«en A se muere 1.13 veces más»

El orden se invirtió, y ahora la comparación coincide con lo que dicen las tasas por edad —A es peor en los tres grupos— porque es lo mismo que están midiendo.

Nótese que la TME de A (8.835) no se parece a su tasa bruta (5.075). Eso es normal y no es un error: la TME **no es la tasa de A**, es la tasa que A tendría con otra estructura. Es un número **contrafactual**, construido para comparar, y no debe reportarse como si fuera la mortalidad observada de la entidad.

QUÉ HAY QUE REPORTAR SIEMPRE

Una tasa estandarizada **no significa nada sin decir con qué estándar se calculó**. Dos informes que estandaricen la misma entidad con estándares distintos darán números distintos, y los dos serán correctos.

Así que la regla es: reportar la tasa estandarizada, **el estándar usado** y, cuando se pueda, la tasa bruta al lado. Las agencias internacionales usan estándares publicados —la población mundial de la OMS, la europea de Eurostat— justamente para que los informes sean comparables entre sí.

Compruébalo. La TME de la entidad A salió 8.835 ‰ y su tasa bruta observada es 5.075 ‰. ¿Cómo se reporta correctamente?

- ☐ a) «La tasa de mortalidad de A es 8.835 por mil.»
- ☐ b) «La tasa de A estandarizada con la estructura nacional es 8.835 por mil; su tasa bruta observada es 5.075 por mil.»
- ☐ c) Hay un error de cálculo: la TME debería parecerse a la tasa bruta.
- ☐ d) «La tasa de mortalidad de A está entre 5.075 y 8.835 por mil.»

4. Estandarización indirecta y la razón de mortalidad

10 min

El método directo necesita las tasas por edad de la población de estudio. Muchas veces **no se tienen**: en municipios pequeños las defunciones por grupo de edad son tan pocas que la tasa es puro ruido, o de plano el registro no las desglosa. Para eso está el otro método.

DEFINICIÓN (MÉTODO INDIRECTO Y RME)

Se toman las tasas del **estándar** y se aplican a la **estructura de la población de estudio**, para obtener las **defunciones esperadas**:

$$D^{\text{esp}} = \sum_x c_x^{\text{estudio}} \cdot {}_nM_x^s.$$

La **razón de mortalidad estandarizada** compara lo observado con eso:

$$\text{RME} = \frac{D^{\text{obs}}}{D^{\text{esp}}}, \quad \text{y} \quad \text{tasa indirecta} = \text{RME} \times \text{TBM}^s.$$

En inglés la RME es el *SMR*, y así aparece en la literatura. Se lee directo: RME = 1.09 significa **9% más defunciones de las que se esperarían** si esa población tuviera la mortalidad del estándar.

LOS DOS MÉTODOS, UNO JUNTO AL OTRO

	directo	indirecto
usa las tasas de...	la población de estudio	el estándar
usa la estructura de...	el estándar	la población de estudio
necesita	las ${}_nM_x$ del estudio	solo el total de defunciones del estudio
sirve cuando	hay buen desglose por edad	la población es pequeña o el dato falta

Los dos **intercambian** qué se toma de dónde, y esa simetría es la forma más fácil de no confundirlos: *directo* pone la estructura ajena, *indirecto* pone las tasas ajenas.

EJEMPLO 5 · LAS DOS ENTIDADES POR EL MÉTODO INDIRECTO

Hacen falta las tasas del estándar, que son ${}_nM_x^s = (1.2, 2.7, 52.0) \text{‰}$, y su tasa bruta:

$$\text{TBM}^s = (0.27)(1.2) + (0.61)(2.7) + (0.12)(52.0) = 0.324 + 1.647 + 6$$

Entidad A. Con su propia estructura y las tasas del estándar:

$$D_A^{\text{esp}} = (0.35)(1.2) + (0.60)(2.7) + (0.05)(52.0) = 0.420 + 1.620 + 2.60$$

Y su observado es 5.075 ‰, así que

$$\text{RME}_A = \frac{5.075}{4.640} = 1.094 \quad \Rightarrow \quad \text{tasa indirecta}_A = (1.094)(8.21$$

Entidad B. El mismo procedimiento:

$$D_B^{\text{esp}} = (0.20)(1.2) + (0.62)(2.7) + (0.18)(52.0) = 0.240 + 1.674 + 9.36$$

$$\text{RME}_B = \frac{10.750}{11.274} = 0.954 \quad \Rightarrow \quad \text{tasa indirecta}_B = (0.954)(8.2$$

Las RME se leen solas: **A tiene 9.4% más defunciones de las esperadas y B tiene 4.6% menos.** El método indirecto llega a la misma conclusión que el directo — A es peor que B — por un camino que no usó las tasas por edad de ninguna de las dos entidades para el cálculo central.

LOS DOS MÉTODOS NO DAN LO MISMO, Y ESO NO ES UN ERROR

	directa	indirecta
A	8.835 ‰	8.98 ‰
B	7.795 ‰	7.83 ‰

Se parecen pero no coinciden, y no tienen por qué: son **promedios ponderados distintos** de las mismas cosas. Siegel & Swanson documentan casos donde la diferencia es enorme —para Ecuador, la tasa ajustada por el método indirecto resultó el doble que la del método directo—.

La consecuencia práctica: **no se comparan RME calculadas con estándares distintos**, ni una tasa directa con una indirecta. Lo que se compara son números contruidos de la misma manera.

Compruébalo. Un municipio pequeño registró 40 defunciones en el año. Su desglose por grupo de edad existe pero tiene tan pocos casos por grupo que las tasas salen erráticas. ¿Qué método de ajuste conviene, y por qué?

- ☐ a) El directo, con la estructura nacional como estándar.
- ☐ b) Ninguno: sin tasas por edad confiables no se puede ajustar por edad.
- ☐ c) El indirecto: aplicar las tasas del estándar a la estructura del municipio y comparar las defunciones esperadas contra las 40 observadas.
- ☐ d) El directo, usando las tasas nacionales como si fueran las del municipio.

5. Qué estándar elegir, y qué no arregla la estandarización

6 min

EJEMPLO 6 · EL MISMO PAR, CON CUATRO ESTÁNDARES DISTINTOS

Estandarizando A y B con cuatro estructuras diferentes:

estándar	TME de A	TME de B	razón A / B
nacional (0.27, 0.61, 0.12)	8.835	7.795	1.133
estructura de A	5.075	4.350	1.167
estructura de B	12.060	10.750	1.122
uniforme (1/3 cada grupo)	19.833	17.833	1.112

Dos lecturas, y las dos importan. La primera: **los niveles cambian mucho** —de 5.1 a 19.8 para la misma entidad A— así que el número absoluto no significa nada por sí solo. La segunda, y es la tranquilizadora: **la razón se mueve poco y el**

orden no cambia, entre 1.11 y 1.17 con los cuatro. La conclusión «A tiene peor mortalidad que B» es robusta a la elección del estándar.

Eso último no está garantizado en general. Cuando las razones por edad van en direcciones opuestas —una población peor en jóvenes y mejor en viejos— la elección del estándar sí puede voltear el resultado, y entonces la respuesta honesta es que **no hay una comparación única** y hay que reportar las tasas por edad. Aquí A era peor en los tres grupos, y por eso ningún estándar puede rescatar a B.

LO QUE LA ESTANDARIZACIÓN NO ARREGLA


1. **No arregla datos malos.** Si el subregistro de defunciones es distinto entre las dos poblaciones, estandarizar propaga el sesgo con más autoridad.
2. **No controla nada más que la edad** — o la variable que se use como peso. Dos entidades pueden diferir en pobreza, altitud o cobertura de salud, y eso sigue dentro de las tasas específicas.
3. **No es un dato observado.** Una TME es un contrafactual: la tasa que la entidad tendría con otra estructura. Reportarla como «la tasa de mortalidad de la entidad» es incorrecto.

Última. Dos entidades X y Y: X tiene **peor** mortalidad que Y en los grupos jóvenes y **mejor** en los adultos mayores. ¿Qué pasa al estandarizarlas?

- ☐ a) Nada distinto: el resultado no depende del estándar, como con A y B.
- ☐ b) El orden puede cambiar según el estándar, así que no hay una comparación única y hay que reportar las tasas por edad.
- ☐ c) Hay que usar el estándar nacional, que es el oficial, y reportar solo ese resultado.
- ☐ d) La estandarización no se puede aplicar cuando las tasas por edad se cruzan.

Mueve la estructura y mira qué se mueve

El deslizador envejece o rejuvenece la entidad A **sin tocar ninguna de sus tasas por edad**. La barra de la tasa bruta se mueve; la de la estandarizada no. Eso es todo lo que hace la estandarización.



estructura de A · proporción de 65+: 5% estándar:

con 65+ al 5%: la tasa BRUTA de A es 5.07‰ y la de B 10.75‰ — según ellas se muere más en B. Las ESTANDARIZADAS son 8.84‰ y 7.79‰, y no se mueven con el deslizador: siempre dicen A. Las tasas por edad de A (1.5, 3.0, 55.0) son mayores que las de B (1.0, 2.5, 50.0) en los tres grupos, así que la respuesta correcta es A.

Cierre y laboratorio

5 min

LO QUE QUEDÓ ESTABLECIDO

- **La identidad que organiza todo:** $TBM = \sum_x c_x n M_x$. La tasa bruta es el promedio de las tasas específicas ponderado por la estructura. Es exacta, sin hipótesis.
- Por eso la tasa bruta mezcla **nivel** (las $n M_x$, lo que se quiere medir) con **estructura** (los c_x , lo que contamina).
- Y por eso puede **invertir la conclusión**: A tiene mortalidad más alta que B en los tres grupos de edad y aun así su tasa bruta es la mitad. Es la paradoja de Simpson.
- **Directo:** $TME = \sum_x c_x^s n M_x$ — las tasas propias con la estructura del estándar.
- **Indirecto:** $D^{esp} = \sum_x c_x n M_x^s$ y $RME = D^{obs} / D^{esp}$ — las tasas del estándar con la estructura propia. Sirve cuando no se tienen las tasas por edad.
- La forma de no confundirlos: **directo pone la estructura ajena, indirecto pone las tasas ajenas.**

- Los dos métodos **no dan el mismo número**, y no tienen por qué. No se comparan entre sí ni con estándares distintos.
- Una tasa estandarizada es un **contrafactual** y no significa nada sin decir con qué estándar se calculó.
- El estándar cambia mucho los **niveles** y poco las **razones** — cuando las tasas por edad no se cruzan. Si se cruzan, no hay comparación única.
- La estandarización no arregla datos malos, no controla más que la variable usada como peso, y no es un dato observado.
- Y e_0 resulta ser un caso de esto: la cohorte de 100 000 es el estándar, siempre el mismo.

EL LABORATORIO 5

Cuatro partes. En la primera se descompone la tasa bruta de tu entidad como $\sum c_{xn} M_x$ y se **verifica que reproduce** la tasa bruta observada — es la comprobación que detecta errores en las tasas o en la estructura. En la segunda se estandariza por el método directo con la estructura nacional. En la tercera se calcula la RME por el método indirecto. Y la cuarta, que vale **3.5 de los 10 puntos**, pide el argumento con sus cuatro piezas: qué dice la tasa bruta de tu entidad, qué dice la estandarizada, cuál de las dos responde la pregunta, y qué NO se puede concluir.

Como en el laboratorio 4, la plantilla trae los datos de referencia listos, así que se puede hacer completo aunque los datos propios no estén. Usar los propios da el criterio correspondiente.

Se entrega el ARCHIVO .ipynb. Dos intentos.

PARA LA SESIÓN 6

Keyfitz & Caswell, capítulo 2. La sesión 6 va un paso más allá: no solo decir que la brecha en e_0 entre dos entidades es de tantos años, sino **repartir esa brecha entre los grupos de edad** — cuántos de los 3.2 años de diferencia vienen de la mortalidad infantil, cuántos de la adulta y cuántos de la de los mayores. Es la descomposición de diferencias, y es la herramienta con la que se decide dónde intervenir.

Simulación de modelos poblacionales (ACD53) · Sesión 5 · Temario 1.3 · Material de sesión, Universidad Michoacana de San Nicolás de Hidalgo · Este documento sirve como notas de lectura y como presentación de clase: usa el botón «Clase» de la barra superior.